

雷浩东

个人主页: [Homepage](#), [GitHub](#), [Google scholar](#)
研究方向: AI Agent Memory, Speculative Sampling
电话/微信: 19521342247 | 邮箱: leihaodong@seu.edu.cn | 现居: 江苏南京



教育背景

东南大学	软件工程	硕士	2024.09-2027.06
PATtern Learning and Mining Lab 成员 研究方向: AI 智能体记忆, 大模型投机采样加速			
海南大学	计算机科学与技术	学士	2020.09-2024.06
GPA: 3.88/4.0, 均分: 90.96 综合排名: 5/123 (4.06%)			

Publications (*denotes equal contribution, †denotes corresponding authors)

H Lei, D Wang^{*†}, H Wang^{*†}, et al. "MemCoT: Test-Time Scaling through Memory-Driven Chain-of-Thought"	First Author, Under Review
H Lei, H Wang[†], et al. "Parallel-Path Relaxed Speculative Jacobi Decoding for Accelerating Auto-Regressive Text-to-Image Generation"	First Author, Under Review
H Lei, H Wang[†], et al. "Fast Inference of Visual Autoregressive Model with Adjacency-Adaptive Dynamical Draft Trees"	First Author, Under Review
X Tan[*], W Weng[*], H Lei, et al. "EasyTune: Efficient Step-Aware Fine-Tuning for Diffusion-Based Motion Generation."	Third Author, ICLR26

实习经历

1、科研任务部-前沿探索中心-算法实习生	上海人工智能实验室	2025.10-至今 上海
AI 智能体长上下文对话记忆: 设计了 MemCoT, 一个用于测试时推理的多尺度记忆系统。解决了 LoCoMo 数据集上的挑战, 该数据集包含 300 多个回合、9000 多个词元, 且对话跨越数月。提出了一种基于记忆-思维的自进化框架, 该框架具有多尺度长期记忆感知能力, 并融合了细粒度检索和粗粒度观察。引入了双重短期记忆(语义轨迹和情境轨迹), 使智能体能够基于历史失败轨迹动态地分解和剪枝复杂查询。在 LoCoMo 数据集上取得了 SOTA, 与纯 RAG 基线相比, GPT-4o-mini 的 F1 值从 42.25 提升至 58.08。以第一作者身份提交至 ACM MM 26。		

科研经历

1、图像自回归大模型推理加速	东南大学&新加坡管理大学	2025. 07-2026. 03
投机采样草稿树推广: 针对自回归文本生成图像模型推理速度慢的问题, 引入多序列草稿树结构, 将传统的 SJD 的链式依赖推广为层次化树状搜索, 显著提升了 Draft Token 的接受率。 图像生成放宽加速: 提出跨序列松弛采样机制 (Cross-Relaxed Strategy), 利用不同序列间的语义相似性进一步优化放宽采样分布。在 Parti-Prompts、MSCOC02017 等标准数据集上验证, 该方法实现了约 4.14x 至 4.18x 的加速比, 性能优于前沿方法。 成果: Parallel-Path Relaxed Speculative Jacobi Decoding for Accelerating Auto-Regressive Text-to-Image Generation, 一作。		
2、PALM 与 SMU 多模态大模型联合项目	东南大学&新加坡管理大学	2024. 07-2025. 07

-
- **图像生成区域相似性加速研究:** 提出树状 Speculative sampling 方法下相邻草稿树的相似性问题. 根据不同像素块对应的草稿树深度与宽度不同, 动态调整草稿树的形状. 设计 Visual AR model 的 Speculative sampling 动态草稿树方法 (ADT-Tree), 使 Anole 模型在 MS-COCO 上的接受长度达到 3.4, 与基线模型相比, 推理加速了 2.21 倍。
 - **成果:** Fast Inference of Visual Autoregressive Model with Adjacency-Adaptive Dynamical Draft Tree, 一作

3、基于文本的动作生成 东南大学&新加坡管理大学 2024.12-2025.11

- **扩散模型后训练:** 提出一种用于扩散模型的微调框架 EasyTune, 通过解耦递归依赖关系实现: (1) 密集高效优化; (2) 内存高效训练; (3) 细粒度对齐。
- **成果:** EasyTune: Efficient Step-Aware Fine-Tuning for Diffusion-Based Motion Generation. (ICLR26, 三作)

实践技能

- 熟悉常见大模型轻量化算法, 包括但不限于蒸馏、投机采样
- 熟悉常见 AI Agent Memory 构建机制与检索机制, 包括但不限于 Rag、知识图谱、Multi-Agent

竞赛经历

2023 海峡两岸暨港澳地区大学生计算机创新作品赛 全国一等奖	2023.06
第 25 届中国机器人及人工智能大赛人工智能创意赛 国家级三等奖	2023.06
2023 中国高校计算机大赛团体程序设计天梯赛“珠峰争鼎” 省级一等奖	2023.05
第 13 届全国大学生数学竞赛大赛 省级一等奖	2021.10